

Anomaly detection in time series, based (not only) on learning representations

Agnieszka Grala, Zuzanna Kurnicka, Patryk Flama

Finalne porównanie 7 metod na pełnym benchmarku NAB

58 szeregów

7 metod

point + event

koszt operacyjny

1. Pytanie badawcze i finalny zakres

Pytanie

Kiedy wystarcza surowy sygnał i prosta statystyka, a kiedy warto uczyć **reprezentację kontekstu czasowego?**

Hipoteza

TS2Vec może lepiej wykrywać anomalie kontekstowe, ale prostsze metody mogą być stabilniejsze, szybsze i łatwiejsze do zamiany na alarmy.

Finalny eksperyment

- ▶ pełny NAB: 58 szeregów, 7 kategorii,
- ▶ 7 metod w jednym porównaniu,
- ▶ point-wise i event-wise evaluation,
- ▶ czas, liczba parametrów i fałszywe alarmy,
- ▶ finalna polityka alarmów peak-window.

2. Dane: pełny Numenta Anomaly Benchmark

58

szeregów

7

kategorii

116

oznaczonych okien

NAB: etykiety są oknami, nie pojedynczymi punktami


prefiks przed pierwszą anomalią okno anomalii



Co utrudnia zadanie?

- ▶ etykieta jest oknem, nie punktem,
- ▶ serie mają różną skalę i dynamikę,
- ▶ anomalia nie zawsze jest ekstremum,
- ▶ istnieją serie bez anomalii,
- ▶ jakość punktowa nie wystarcza do oceny alarmów.

3. Pipeline: od sygnału do alarmu



Model

- ▶ uczy się normalnego wzorca,
- ▶ zwraca anomaly score dla czasu,
- ▶ używa wartości lokalnych, okna historii lub embeddingu TS2Vec.

Materializacja alarmu

- ▶ próg: kwantyl 0.9995 z prefiksu,
- ▶ czyszczenie i jeden lokalny pik,
- ▶ okno 128 punktów ogranicza fragmentację.

Ocena

- ▶ punkt: czy timestamp jest trafiony,
- ▶ event: czy alarm trafia okno NAB,
- ▶ osobno koszt i false positives.

4. Porównane metody

Statystyczne

Robust z-score

Mediana i MAD; odporność na wartości skrajne.

Rolling residual

Odchylenie od lokalnego poziomu szeregu.

Klasyczne i deep

Isolation Forest

Izolacja nietypowych cech punktowych i lokalnych.

MLP autoencoder

Błąd rekonstrukcji okna.

LSTM / GRU

Błąd prognozy następnej wartości.

Representation learning

TS2Vec

Kontrastowa, wieloskalowa reprezentacja kontekstu czasowego.

Anomaly score wynika z nietypowości embeddingu względem normalnego wzorca.

5. Dwa poziomy jakości

Point-wise

Każdy timestamp jest osobną decyzją.

F1, precision, recall, PR-AUC

Mierzy pokrycie etykiet, lecz może premiować długie alarmy.

Event-wise


Alarm jest zdarzeniem, które ma trafić okno NAB.

Event F1, precision, recall

Lepiej odpowiada pytaniu: ile użytecznych alarmów otrzyma operator?

Jeden model może wygrać punktowo i przegrać jako system alarmowy.

6. Wyniki zagregowane: nie ma jednego zwycięzcy



Point F1

- Isolation Forest: **0.326**
- TS2Vec: 0.305


PR-AUC

- MLP-AE: **0.226**
- TS2Vec: 0.208

Event F1

- robust z-score: **0.467**
- TS2Vec: 0.376

7. Event recall nie wystarcza




TS2Vec wykrywa wiele zdarzeń, ale:

- ▶ ma najwyższy event recall,
- ▶ jednocześnie najniższy event precision,
- ▶ dlatego kończy z najniższym event F1.

Robust z-score daje najlepszy kompromis precision–recall w finalnej polityce alarmów.

8. Kategorie NAB wymagają różnych detektorów




TS2Vec jest mocny dla:

- ▶ artificial with anomaly,
- ▶ realTraffic.

Inne kategorie:

- ▶ LSTM wygrywa na AdExchange,
- ▶ z-score jest mocny na KnownCause,
- ▶ brak uniwersalnego rankingu.

9. Logika alarmów zmienia wynik




Dla większości metod

- ▶ rośnie point F1,
- ▶ rośnie event F1,
- ▶ liczba fałszywych zdarzeń mocno spada.

Wyjątek: TS2Vec

- ▶ event F1 rośnie nieznacznie,
- ▶ liczba false events wzrasta,
- ▶ potrzebuje innej kalibracji pików.

10. Efekt nie jest stabilny między szeregami



Najbardziej stabilna poprawa


- ▶ LSTM: poprawa na 40 z 52 szeregów,
- ▶ regresja tylko na 4.

TS2Vec

- ▶ poprawa na 18 szeregach,
- ▶ regresja na 25,
- ▶ agregat ukrywa zmianę rozkładu błędów.

11. Łatwe i trudne zdarzenia


Łatwe: 7/7 metod



Twitter_volume_IBM, okno 14848–15643.

Wyraźna zmiana poziomu i liczne piki odróżniają okno od otoczenia.

Trudne: 0/7 metod




ec2_disk_write_bytes, okno 2964–3099.

Oznaczone okno jest prawie płaskie, a większe piki występują poza nim.

Trudność zależy od kontekstu: anomalia nie musi być największym ekstremum.

12. Koszt operacyjny



Metody statystyczne

- ▶ prawie zerowy koszt,
- ▶ brak treningu sieci,
- ▶ mocny event F1.

Modele deep

- ▶ większy czas i liczba parametrów,
- ▶ koszt nie gwarantuje lepszego alarmowania.

13. Odpowiedź i ograniczenia

Co pokazują wyniki

Pełny NAB nie potwierdza jednej najlepszej metody. Zwycięzca zależy od metryki i kategorii danych.

Główny wniosek

Reprezentacja i logika alarmów są osobnymi problemami. Prostszy model z lepszą polityką zdarzeń może być praktycznie lepszy.

Ograniczenie protokołu

Jedno wspólne okno 128 punktów nie pasuje jednakowo do wszystkich score'ów. Poprawia event F1, ale dla części metod zwiększa point false positives.

14. Podsumowanie

Nie istnieje jeden najlepszy detektor dla całego NAB.

Point F1

Isolation Forest: 0.326

PR-AUC

MLP-AE: 0.226

Event F1

robust z-score: 0.467

TS2Vec wnosi wartościową reprezentację kontekstu, ale największa poprawa systemu wynika z właściwego definiowania i kalibracji alarmów.

Dane: Numenta Anomaly Benchmark | Reprezentacje: Yue et al., TS2Vec (AAAI 2022)